

Regresión polinomial

(Una perspectiva probabilística)

Tarea:

1. Polinomio de grado arbitrario.

Hoy:

1. Subir este código a nuestro GitHub.
2. Siguiendo con el capítulo 1 del Bishop.
 - Sobreajuste y regularización.
 - Una perspectiva probabilística.

Sobreajuste.


Definiendo modelos

$$f(x; \vec{w})$$

Reg. lin. $f(x; w_0, w_1)$

Reg. Polinomial $f(x; w_0, \dots, w_{n-1})$

¿Cuántos parámetros son suficientes?




1. "grado menor que la cant. de datos".

2. Dividir la base de datos

80% / 20%.

↓
Entrenamiento → Prueba.



Errores:

Entrenamiento: $\sum_{i=1}^n (y_i - \hat{y}_i)^2 = 0$ $\sum_{i=1}^n (y_i - \hat{y}_i)^2 > 0$ $\sum_{i=1}^n (y_i - \hat{y}_i)^2 > 0$
Pequeño más grande

Prueba: $\sum_{i=1}^n (y_i - \hat{y}_i)^2$ $\sum_{i=1}^n (y_i - \hat{y}_i)^2 > 0$ $\sum_{i=1}^n (y_i - \hat{y}_i)^2 > 0$
Pequeño más grande que $\sum_{i=1}^n (y_i - \hat{y}_i)^2$



1. Separación entre prueba y entrenamiento.
2. Implementar $\mathcal{E}(w; D)$
3. graficar.

Tarea:

- Generalizar la función que separa los datos de entrenamiento y prueba a cualquier tamaño de x y t .
- Implementar la función error:
$$\mathcal{E}(w) = \sum_n (y(x_n; w) - t_n)^2$$
- Visualizar los errores de entrenamiento y prueba para $M \in \{1, \dots, 2 \cdot N\}$ donde $N = |D|$