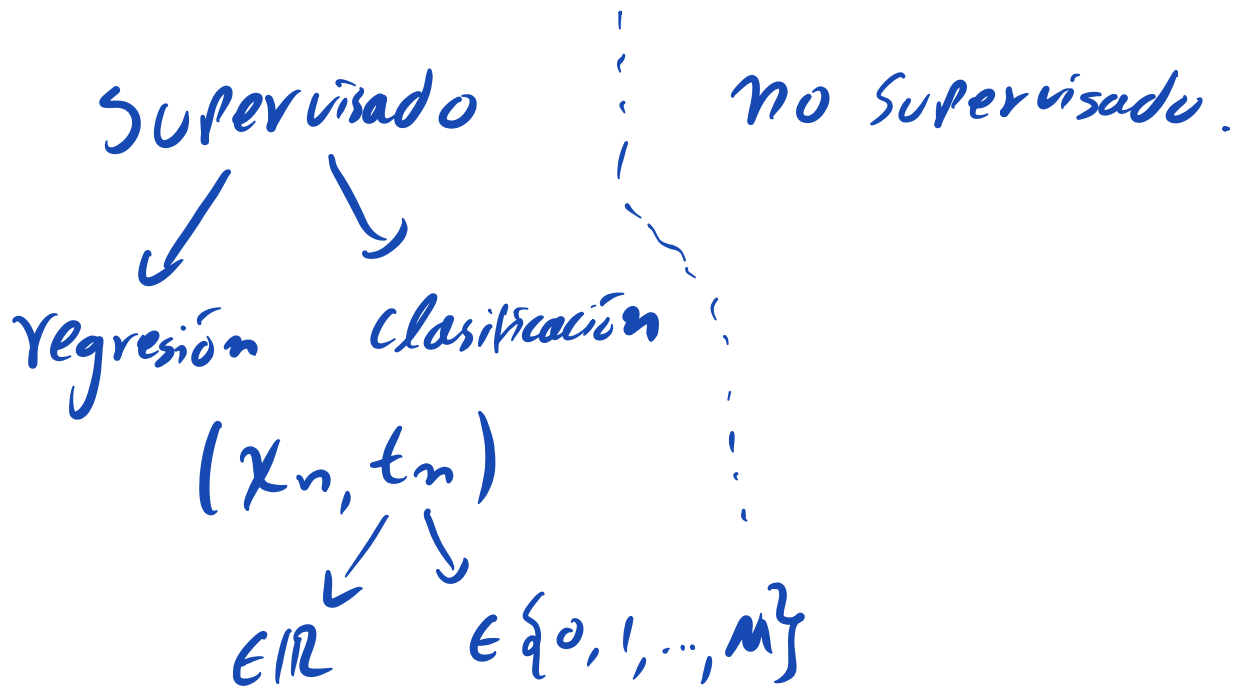


Intro a las redes neuronales.

Resumen:



1. Definir un modelo $y(x; \vec{w})$.
2. Definir una función de error $\xi(\vec{w})$
3. Minimizar $\xi(\vec{w})$ para encontrar los mejores pesos \vec{w} .

ξ_j : Regresión Polinomial

1. $y(x; \bar{w}) = w_0 + w_1 x + \dots + w_m x^m$

2. $\xi(\bar{w}) = \frac{1}{2} \sum (y(x_n; \bar{w}) - t_n)^2$

3. minimizar ξ .

ξ_j : Regresión logística

1. $y(x; w_0, w_1) = \frac{1}{1 + \exp(-(w_0 + w_1 x))}$
Sigmoidal.

2. $\xi(w_0, w_1) = \dots$
Entropía binaria
Cruzada.

binary cross-entropy.


3. minimizar $\xi(\vec{w})$?


no lo podemos hacer
analíticamente, entonces
descendemos por el
gradiente.

¡Pensemos más general!


$$y(x; \vec{w}) = w_0 + w_1 x$$

regresión lineal.






$$y = x_1 w_1 + x_2 w_2 + w_0$$



$$y = w_0 + w_1 x + \dots + w_n x^n$$



$$h_0 = x_1 w_{10}^x + x_2 w_{20}^x$$

$$h_1 = x_1 w_{11}^x + x_2 w_{21}^x$$

$$y = h_0 w_0^h + h_1 w_1^h$$



$$\vec{h} = \begin{bmatrix} h_0 \\ h_1 \end{bmatrix}, \quad w^x = \begin{bmatrix} w_{10}^x & w_{20}^x \\ w_{11}^x & w_{21}^x \end{bmatrix}$$

$$\vec{h} = w^x{}^T \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$y = \begin{bmatrix} w_0^h \\ w_1^h \end{bmatrix}^T \vec{h}$$

- Podemos representar
 Una regresión lineal/polin.
 Como un grafo donde
 los pesos son las aristas
 y la información fluye

de derecha a izquierda.



Def: Una neurona es una función que toma la siguiente forma:

$$h(\vec{x}; \vec{w}) = f(\vec{w}^T \vec{x})$$

Ej: Logística

$$\sigma(x; w_0, w_1) = \frac{1}{1 + \exp(-w_0 - w_1 x)}$$

Ej: Regresión lineal

$$f(x; w_0, w_1) = w_0 + w_1 x$$

Notación: a f la llamamos
función de activación.

→ en reg. lineal, la
función de activación es
la identidad

→ en reg. logística, la
fun. de activación es
la sigmoïdal.

Ej: \tanh , ReLU .

¿Cómo computamos el gradiente de una neurona respecto a los pesos?

$$h(t(\vec{w}))$$

$$\nabla_{\vec{w}} h(\vec{w}^T \vec{x})$$

$$\frac{\partial}{\partial w_j} h(w_1 x_1 + \dots + w_n x_n)$$

$$x_j \cdot \frac{\partial h}{\partial (w_1 x_1 + \dots + w_n x_n)}$$